

# Correção A1 - ALN

Beatriz Lúcia

April 2025

## 1

### 1.1

(V).

$$\|x\|_2 = \|x\|_3 \implies x = e_i \quad \text{ou} \quad x = 0$$

Em ambos os casos, teremos

$$\|x\|_p = \|x\|_2 = \|x\|_3, \quad \forall p \in N$$

### 1.2

(F)

$$I = Q^t Q$$

e portanto, os valores singulares de  $Q$  são todos 1. Assim,  $\Sigma = I$ . Seja

$$Q = U \Sigma V^t = UV^t$$

uma decomposição SVD de  $Q$ . Tome, por exemplo,  $Q = I$ . Podemos escolher

$$U = I, V = I$$

. Também podemos tomar:

$$U = \begin{bmatrix} -1 & 0 \\ 0 & 1 \end{bmatrix}, \quad \Sigma = I, \quad V = \begin{bmatrix} -1 & 0 \\ 0 & 1 \end{bmatrix}$$

e verificar que:

$$\begin{aligned} U \Sigma V^T &= \begin{bmatrix} -1 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} -1 & 0 \\ 0 & 1 \end{bmatrix}^T \\ &= \begin{bmatrix} -1 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} -1 & 0 \\ 0 & 1 \end{bmatrix} \\ &= \begin{bmatrix} -1 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} -1 & 0 \\ 0 & 1 \end{bmatrix} \\ &= \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} = I \end{aligned}$$

### 1.3

(F)

$$A = \begin{bmatrix} 1 & 2 \\ 2 & 1 \end{bmatrix}$$

$$M_J = - \begin{bmatrix} 0 & 2 \\ 2 & 0 \end{bmatrix}$$

cujos autovalores são  $\lambda_1 = 2, \lambda_2 = -2$ . Portanto, o método de Jacobi diverge.

### 1.4

(F)

$$\kappa(f, x) = \left| \frac{xf'(x)}{f(x)} \right| = \left| \frac{x \cdot \frac{1}{2\sqrt{1+x}}}{\sqrt{1+x}} \right| = \left| \frac{x}{2(1+x)} \right|$$

quando  $x \rightarrow -1, \kappa(f, x) \rightarrow \infty$

## 2

$$A = \begin{bmatrix} a & b \\ c & d \end{bmatrix}$$

### 2.1

$$M_J = D^{-1}(-L - U) = - \begin{bmatrix} a & 0 \\ 0 & d \end{bmatrix}^{-1} \begin{bmatrix} 0 & b \\ c & 0 \end{bmatrix} = - \begin{bmatrix} \frac{1}{a} & 0 \\ 0 & \frac{1}{d} \end{bmatrix} \begin{bmatrix} 0 & b \\ c & 0 \end{bmatrix}$$

$$M_J = - \begin{bmatrix} 0 & \frac{b}{a} \\ \frac{c}{d} & 0 \end{bmatrix}$$

Cujos autovalores sejam  $\lambda_1 = (\frac{bc}{ad})^{\frac{1}{2}}$  e  $\lambda_2 = -(\frac{bc}{ad})^{\frac{1}{2}}$

### 2.2

A matriz de iteração de Gauss-Seidel  $M_{GS}$  é dada por:

$$M_{GS} = -(D + L)^{-1}U$$

O inverso de  $D + L = \begin{bmatrix} a & 0 \\ c & d \end{bmatrix}$  é:

$$(D + L)^{-1} = \begin{bmatrix} \frac{1}{a} & 0 \\ -\frac{c}{ad} & \frac{1}{d} \end{bmatrix}$$

Multiplicando  $-(D + L)^{-1}$  por  $U$ , obtemos:

$$M_{GS} = \begin{bmatrix} 0 & -\frac{b}{a} \\ 0 & \frac{bc}{ad} \end{bmatrix}$$

Os autovalores de  $M_{GS}$  são as raízes da equação:

$$\det(M_{GS} - \lambda I) = \begin{vmatrix} -\lambda & -\frac{b}{a} \\ 0 & \frac{bc}{ad} - \lambda \end{vmatrix} = (-\lambda) \left( \frac{bc}{ad} - \lambda \right)$$

Portanto, os autovalores de  $M_{GS}$  são  $\lambda_1 = 0$  e  $\lambda_2 = \frac{bc}{ad}$ .

## 2.3

Considere a matriz:

$$A = \begin{bmatrix} 2 & 2 \\ 2 & 3 \end{bmatrix}$$

Esta matriz não é diagonalmente dominante e note que  $\frac{bc}{ad} < 1$  e portanto, todos os autovalores de  $M_J$  são menores que 1. Concluimos que o método de Jacobi converge

## 3

Seja  $P$  uma matriz de projeção oblíqua em  $R^m$ , isto é,  $P^2 = P$ .

### 3.1

Para  $x \in R^m$ , defina  $s(x) = \frac{\|Px\|_2}{\|x\|_2}$ . Quais os valores máximo e mínimo de  $s(x)$ ?

$$\max s(x) = \max \frac{\|Px\|_2}{\|x\|_2} = \|P\|_2 = \sqrt{\rho(P^T P)} = \sigma_{max}$$

onde  $\rho(P^T P)$  é o raio espectral da matriz  $P^T P$ ,  $\sigma_{max}$  = maior valor singular de  $P$ .

$$\min s(x) = \min \frac{\|Px\|_2}{\|x\|_2} = \sigma_{min}(P)$$

se  $P$  não tem posto completo, corresponde a  $x \in Ker(P)$ ,  $Px = 0$ .

### 3.2

Dê um exemplo de uma matriz  $P$  e dois vetores  $x_1$  e  $x_2$  tais que  $s(x_1) > 1$  e  $s(x_2) < 1$ .

$$P = \begin{bmatrix} 2 & -1 \\ 2 & -1 \end{bmatrix}$$

$$P^2 = \begin{bmatrix} 2 & -1 \\ 2 & -1 \end{bmatrix} \begin{bmatrix} 2 & -1 \\ 2 & -1 \end{bmatrix} = \begin{bmatrix} 2 & -1 \\ 2 & -1 \end{bmatrix} = P$$

$$x_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}, x_2 = \begin{bmatrix} 1 \\ 2 \end{bmatrix}$$

$$Px_1 = \begin{bmatrix} 2 \\ 2 \end{bmatrix} \implies \frac{\|Px_1\|}{\|x_1\|} = \frac{\sqrt{8}}{\sqrt{1}} = \sqrt{8} > 1$$

$$Px_2 = \begin{bmatrix} 0 \\ 0 \end{bmatrix} \implies \frac{\|Px_2\|}{\|x_2\|} = 0 < 1$$

### 3.3

Calcule o número de condicionamento absoluto da função  $f : x \mapsto Px$ , com relação à norma euclidiana.

$$k_{abs}(f) = \sup \frac{\|f(x)\|_2}{\|x\|_2} = \sup s(x) = \sqrt{\rho(P^T P)}$$

### 3.4

Qual o número de condicionamento relativo de  $f$ ? Compare as respostas com o número de condicionamento da matriz  $P$ .

$$k_{rel}(f) = \sup \frac{\|D(f(x))\|_2 \|x\|_2}{\|Px\|_2} = \|P\|_2 \sup \frac{\|x\|_2}{\|Px\|_2} = \|P\|_2 \frac{1}{\inf s(x)} = \frac{\max s(x)}{\min s(x)} = \frac{\sigma_{max}(P)}{\sigma_{min}(P)}$$

Condicionamento da matriz  $P$ :

$$\kappa(P) = \frac{\sigma_{max}(P)}{\sigma_{min}(P)}$$

$$k_{rel}(f) = \kappa(P)$$

quando  $P$  é invertível. No caso de projeção oblíqua,  $P$  não é invertível, e portanto  $\sigma_{min}(P) = 0$ , levando a  $k_{rel}(f) = \infty$ .

### 3.5

O que muda se a projeção for ortogonal? (Isso não quer dizer que a matriz  $P$  é ortogonal!)

$$P^T = P$$

e como antes

$$P^2 = P$$

Neste caso, os autovalores da matriz são 0 ou 1. Mudamos o máximo da função  $s(x)$  para 1, e o mínimo para 0. Ainda temos

$$k_{\text{rel}}(f) = \kappa(P)$$

e

$$k_{\text{abs}} = 1$$

exemplo:

$$P = \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix}$$

## 4

Vimos em aula que podemos usar a fatoração QR para resolver problemas de mínimos quadrados, com sistemas sobredeterminados. Esta questão é o caso “complementar”, onde temos menos equações do que incógnitas. Para fixar uma solução, também vamos usar um critério de otimização: queremos minimizar a norma euclidiana da solução.

Seja  $A$  uma matriz  $m \times n$  com  $m \leq n$ , de posto completo, e seja  $b \in R^m$ .

### 4.1

Calcule a dimensão de  $S_b = \{x \in R^n \mid Ax = b\}$

Tome  $x_0 \in S_b$ . Podemos escrever  $S_b = x_0 + k$ , onde  $k \in \text{Ker}(A)$ . Portanto,  $\dim(S_b) = \dim(\text{Ker}(A))$ . Sabemos que

$$\dim(\text{Ker}(A)) + \dim(\text{Im}(A)) = n$$

onde  $n$  é o número de colunas. Como  $A$  é full rank, temos  $\dim(\text{Im}(A)) = m$ . Consequentemente,  $\dim(S_b) = n - m$ .

### 4.2

$S_b$  é paralelo a um dos 4 espaços fundamentais de  $A$ . Qual?

Pela questão anterior, é evidente que  $S_b$  é paralelo ao  $\text{Ker}(A)$

### 4.3

Seja  $z$  o vetor com a menor norma euclidiana em  $S_b$ . Mostre que  $z \perp \ker(A)$ .

Podemos escrever  $z = x_0 + k$ , onde  $k \in \ker(A)$

$$\min \|z\|^2$$

restrito a

$$k \in \ker(A)$$

**Forma complicada:**

$$L(k, \lambda) = \|x_0\|^2 + 2 \langle x_0, k \rangle + \|k\|^2 + \langle \lambda, Ak - 0 \rangle$$

$$\frac{dL}{dk} = 2x_0 + 2k + A^T \lambda = 0 \implies k = -x_0 - 0.5A^T \lambda$$

$$\frac{dL}{d\lambda} = Ak = 0 = A(-x_0 - 0.5A^T \lambda) \implies \lambda = -2((AA^T)^{-1})Ax_0 = -2((AA^T)^{-1})b$$

Então,

$$k^* = -x_0 + A^T(AA^T)^{-1}b \implies z^* = A^T(AA^T)^{-1}b$$

para qualquer  $w \in \ker(A)$ , temos:

$$\langle z^*, w \rangle = b^T((AA^T)^{-1})^T Aw = 0$$

Portanto,  $z^*$  é ortogonal ao  $\ker(A)$

**Forma mais simples:**

$$\text{dist}(0, S_b) = \text{dist}(\ker(A), S_b) = V$$

$$\|x\|^2 = \|V + k\|^2 = \|V\|^2 + \|k\|^2$$

$\|x\|$  será minimizada quando  $\|k\| = 0$ , ou seja, quando  $x$  for perpendicular ao  $\ker(A)$

### 4.4

conclua que  $z \in \text{im}(A^*)$

$$z^* \in (\ker(A))^{\perp} = \text{Im}(A^T)$$

### 4.5

Seja então  $A^* = QR$  uma fatoração QR reduzida de  $A^*$ . Quais as dimensões das matrizes  $Q$  e  $R$ ?

$A^*$  tem dimensão  $n \times m$  Dimensão de  $Q = n \times m$ , não geramos o restante dos vetores para formar uma base em  $\mathcal{R}^n$ . Dimensão de  $R$  é  $m \times m$ .

## 4.6

Explique por que existe  $y$  tal que  $z = Qy$ .  $Qy$  gera uma combinação das colunas de  $Q$ , onde as colunas de  $Q$  são a base para  $A^T$ .

Como  $z \in \text{Im}(A^T)$  temos que  $z$  é uma combinação linear das colunas de  $A^T$  é portanto, uma combinação linear das colunas de  $Q$ .

## 4.7

Dê o sistema linear que permite calcular  $y$ , e deduza uma fórmula para a solução  $z$ .

$$z = Qy$$

e

$$Az = b$$

onde  $A^T = QR$

então,

$$Az = b \implies R^T Q^T Qy = R^T y = b$$

Portanto,

$$y = (R^T)^{-1}b, z = Q(R^T)^{-1}b$$

---

**usando o resultado da minimização, podemos fazer:**

$$z = A^T(AA^T)^{-1}b = QR(R^T R)^{-1}b = Q(R^T)^{-1}b \implies y = Q^T z = (R^T)^{-1}b$$

(não necessário!)

## 4.8

Compare esta fórmula com a da solução do problema de mínimos quadrados.

Solução do problema de mínimos quadrados de  $A^T x = w$  nos dá  $x = (AA^T)^{-1}Aw = (R^T R)^{-1}R^T Q^T w = R^{-1}Q^T w$